

Memoria proyecto gemelos digitales

Optimización del Transporte público de Madrid

Bernardo Quindimil Micó
Jacqueline Ferrin Meilan

1. Definición del problema y contexto.....	3
2. Estado del arte y antecedentes.....	3
2.1. Gemelo Digital de Singapur: Land Transport Authority.....	4
2.2 Predicción de Demanda en San Sebastián: Proyecto HUPI.....	5
2.3 Simulación de Tráfico: Suite SUMO.....	5
2.4 Sistema AGIT de París: Machine Learning para Predicción de Tráfico.....	6
3. Arquitectura propuesta.....	6
3.1 Diagrama Global de Componentes:.....	7
3.2 Componentes Clave.....	7
3.3 Flujos de Datos entre Componentes.....	9
4. Implementación detallada.....	10
4.1 Descripción técnica de cada módulo del prototipo.....	10
4.2 Código Relevante y Evidencias.....	10
5. Resultados y Validación.....	11
5.1 KPIs y Métricas Obtenidas.....	11
5.1.1. Interacción del Usuario (Tab Switches).....	11
5.1.2. Rendimiento del Sistema (API Calls).....	11
5.1.3. Observabilidad Visual.....	11
5.2 Validación Funcional.....	12
5.3 Limitaciones y lecciones aprendidas.....	13
6. Conclusiones y futuras mejoras.....	13
6.1 Valor generado por el prototipo.....	13
6.2 Posibles avances futuros.....	13
6.3 Transferibilidad a otros ámbitos/sectores.....	13
7. Imágenes Interfaz.....	14
8. Enlace repositorio.....	15
9. Referencias.....	15

1. Definición del problema y contexto

El transporte público urbano en Madrid enfrenta desafíos críticos que impactan tanto la experiencia del usuario como la eficiencia operativa, algunos de ellos podrían ser:

- Congestión y tiempos de espera impredecibles: Los usuarios no tienen acceso a información precisa y en tiempo real sobre la ocupación de autobuses, disponibilidad de servicios y tiempos de llegada ajustados a la demanda actual.
- Ineficiencia en la planificación operativa: Las autoridades de transporte (EMT) planifican recursos basándose en datos históricos, sin capacidad predictiva de cambios en la demanda.
- Falta de optimización de rutas: Los sistemas actuales no adaptan dinámicamente las rutas según la demanda en tiempo real.
- Baja accesibilidad a datos: No existe una plataforma integrada que combine datos de transporte público con visualización geoespacial.

La implementación de un gemelo digital inteligente de una plataforma que integre los servicios de transporte tendría una gran relevancia teniendo en cuenta que en 2024 el transporte público madrileño batió récord histórico tras ser usado por 1.722 millones de usuarios. Además tanto los costos operativos como los niveles de contaminación tendrían una reducción significativa.

Por todos estos motivos, se decide realizar un gemelo digital del sistema de transporte público de Madrid a través la API pública de la EMT (Empresa Municipal de Madrid) que proporciona los datos a tiempo real, permitiendo una simulación más fiel a la realidad.

Con esta aplicación los usuarios podrán tener acceso a predicciones de ocupación y tiempos de espera, y planificaciones adaptativas según el recorrido ante cualquier avería o imprevisto, mejorando de esta manera la experiencia del usuario significativamente.

2. Estado del arte y antecedentes

Como definición general, los gemelos digitales son una réplica virtual de un sistema físico que recibe datos en tiempo real y permite simulación, análisis y predicciones de comportamientos futuros.

En el ámbito de la gestión de infraestructuras urbanas, los gemelos digitales representan una gran evolución, permitiendo la creación de representaciones virtuales sincronizadas con sistemas físicos en tiempo real. Más específicamente, en el contexto del transporte público urbano, esta tecnología ha emergido como una solución integral para abordar desafíos críticos de congestión, optimización de recursos y experiencia del usuario, además de haber derivado también a realizar esquemas predictivos gracias su integración múltiple de capas de información.

Estudios recientes de Berkeley indican que los gemelos digitales aplicados a sistemas de tránsito urbano pueden generar reducciones de tiempo de viaje entre 8-12% y mejorar la sincronización de servicios hasta en un 15% . Sin embargo, la implementación de estas soluciones requiere arquitecturas complejas que integren tecnologías heterogéneas, desde sistemas IoT de adquisición de datos hasta plataformas de machine learning avanzado y herramientas de visualización geoespacial sofisticada.

A continuación se presentan en este documento tecnologías emergentes y soluciones existentes relacionadas con la propuesta.

2.1. Gemelo Digital de Singapur: Land Transport Authority

La Land Transport Authority de Singapur desarrolló un gemelo digital urbano que integra datos provenientes de GPS, sistemas de recaudación de tarifas, cámaras CCTV y feeds meteorológicos en tiempo real . La arquitectura propuesta utiliza la plataforma Esri ArcGIS para análisis geoespacial y VISSIM para simulación microscópica de tráfico, permitiendo modelar comportamientos de congestión a escala de vehículo individual. La solución implementa algoritmos de machine learning para predicción de congestión con horizonte de 30 minutos, generando recomendaciones automáticas de redireccionamiento de tráfico.

Los resultados operativos demostraron reducción del tiempo promedio de viaje del 8%, decremento de retrasos en autobús del 12% y mejora sustancial en la sincronización de semáforos adaptativa. No obstante, este modelo presenta limitaciones significativas: requiere inversión capital masiva en infraestructura (infraestructura computacional dedicada, sensorización extensa), las arquitecturas son frecuentemente propietarias y cerradas, y el

costo de replicación hacia otras ciudades es prohibitivo. Adicionalmente, la solución de Singapur depende fuertemente de hardware especializado, limitando su escalabilidad y accesibilidad para ciudades medianas o con presupuestos públicos limitados.

2.2 Predicción de Demanda en San Sebastián: Proyecto HUPI

El proyecto HUPI (Hueco de Información y Predicción Urbana) desarrollado en colaboración entre la Universidad de Deusto y el operador de transporte DBUS de San Sebastián presenta un enfoque alternativo centrado en predicción de ocupación mediante algoritmos de inteligencia artificial sin requerimientos de hardware adicional. Este sistema integra datos abiertos públicos, incluyendo información histórica de ocupación, pronósticos meteorológicos de OpenWeather API y calendarios de eventos especiales.

La metodología empleada utiliza técnicas de aprendizaje automático supervisado, incluyendo redes neuronales convolucionales para captura de patrones temporales complejos y algoritmos de ensamble (random forests, gradient boosting) para validación cruzada de predicciones. Las predicciones se generan con horizonte de tres días de anticipación, permitiendo a operadores ajustar asignaciones de flota de manera proactiva. Los resultados reportan precisión en predicción de ocupación agregada superior al 85%, con errores medios absolutos inferiores al 12%.

Las ventajas comparativas del enfoque HUPI incluyen bajo costo de implementación (aprovecha infraestructura existente), automatización completa sin intervención de especialistas en data science, y escalabilidad inmediata hacia nuevas ciudades. Sin embargo, presenta limitaciones críticas: la predicción operacionaliza únicamente demanda agregada por línea horaria, no permite granularidad a nivel de parada individual, carece de componente de visualización geoespacial interactiva, y emplea arquitectura centralizada sin capacidad de integración de datos adicionales en tiempo real.

2.3 Simulación de Tráfico: Suite SUMO

SUMO (Simulation of Urban Mobility) constituye una herramienta fundamental de código abierto desarrollada por el Deutsche Zentrum für Luft- und Raumfahrt. Esta plataforma permite simulación microscópica de tráfico urbano con nivel de detalle a escala de vehículo individual, soportando múltiples modos de transporte (automóviles, transporte público, bicicletas, peatones) en redes urbanas de complejidad arbitraria.

La arquitectura de SUMO se fundamenta en un modelo de movimiento basado en física, donde cada vehículo sigue comportamientos de aceleración/desaceleración realista. La plataforma proporciona API de control en Python (TraCI: Traffic Control Interface) que permite manipulación en tiempo real de parámetros de simulación, inyección de vehículos, y recolección de métricas telemáticas. Capacidades adicionales incluyen conversión automática de mapas OpenStreetMap a redes de simulación, compatibilidad con estándares de tránsito (GTFS), y extensibilidad mediante plugins personalizados.

Las fortalezas de SUMO radican en su naturaleza open-source, comunidad de usuarios activa (más de 5,000 instituciones académicas e industriales), y flexibilidad para modelar escenarios complejos. Las limitaciones incluyen curva de aprendizaje pronunciada (requiere dominio de formatos XML complejos), calibración manual consumidora de tiempo para parámetros de simulación específicos del contexto local, ausencia de interfaz web nativa para visualización interactiva, y limitaciones computacionales para simulaciones de ciudades completas en tiempo real.

2.4 Sistema AGIT de París: Machine Learning para Predicción de Tráfico

El sistema AGIT (Análisis y Gestión Inteligente del Tráfico) implementado en la zona de La Défense en París representa una solución híbrida que combina técnicas de machine learning avanzado con integración operacional directa. La arquitectura implementa modelos predictivos de tráfico con horizonte de 15 minutos, permitiendo alertas automáticas a centros de control de tráfico.

La metodología incorpora algoritmos de redes neuronales recurrentes (Long Short-Term Memory, LSTM) para captura de dependencias temporales complejas, complementadas con técnicas de gradient boosting (XGBoost) para mejorar robustez predictiva. El sistema integra datos de múltiples sensores fijos (detectores inductivos en vías), información de GPS de vehículos conectados, y patrones históricos de congestión. La evaluación reporta precisión superior al 88% en predicción de velocidades de tráfico.

Las capacidades innovadoras incluyen adaptación automática de modelos ante cambios de patrón de tráfico, integración directa con sistemas de control urbano existentes, y generación de recomendaciones prescriptivas (sugerencias de redireccionamiento). Las limitaciones observadas son: solución propietaria con costo de implementación elevado, dependencia de datos propietarios de operadores, complejidad de mantenimiento de modelos predictivos, y limitada transferibilidad a contextos urbanos diferentes.

Caso de Estudio	Enfoque Principal	Tecnología / Metodología	Ventajas	Limitaciones Clave
Singapore (Land Transport Authority)	Gemelo Digital Urbano (Simulación)	Integración de datos (GPS, CCTV), Esri ArcGIS, VISSIM (simulación microscópica).	Reducción del tiempo de viaje (8%), mejora en sincronización y redireccionamiento automático.	Alto costo de replicación , dependencia de hardware especializado
San Sebastián (Proyecto HUPI)	Predicción de Demanda/Ocupación	Algoritmos de Machine Learning (Redes Neuronales Convolucionales, Ensamble) sobre datos abiertos.	Bajo costo de implementación, aprovecha la infraestructura existente.	Sin visualización geoespacial interactiva.
SUMO (Software Open Source)	Simulación de Tráfico Microscópica	Plataforma Open-Source basada en física. API de control en Python (TraCI).	Código abierto, comunidad activa, flexibilidad para modelar escenarios complejos.	Limitaciones computacionales para simulaciones de ciudades completas en tiempo real.
París (Sistema AGIT)	Predicción de Tráfico/Velocidad	Redes Neuronales Recurrentes (LSTM) y Gradient Boosting (XG Boost).	Alta precisión, integración operacional directa.	Costo elevado. Complejidad de mantenimiento de modelos.

3.Arquitectura propuesta

Para la realización de este proyecto se opta por una arquitectura basada en un modelo de tres capas que permite la obtención, procesamiento y visualización de información sobre el estado actual del transporte público y servicios de movilidad en la ciudad.

3.1 Diagrama Global de Componentes:

Los tres niveles principales de esta arquitectura son los siguiente los cuales están interconectados.



Capa de Datos: Se encuentran los sensores virtuales que consumen información desde las APIs REST de EMT Madrid (BiciMAD, Autobuses, Parkings). A estas se suman dos servicios externos clave: la API de Meteoblue para datos meteorológicos y OpenRouteService para el cálculo de rutas y navegación.

Capa Intermedia (Integración): Constituida por la plataforma n8n, que actúa como middleware orquestador. Gestiona tres vías principales: la entrega de datos de movilidad, la gestión de consultas externas (clima y rutas) y la captura de interacciones del usuario y KPIs hacia el sistema de monitorización.

Capa de Persistencia y Monitorización: Se integra una base de datos PostgreSQL con extensión TimescaleDB para almacenar series temporales de métricas, conectada a Grafana para la visualización de KPIs operativos.

Capa de Presentación: Aplicación web interactiva (SPA) con mapas georreferenciados (Leaflet), visualización de trazado de rutas y un sistema de recomendación inteligente.

3.2 Componentes Clave

Para realizar esta practica se han utilizado varias fuentes de datos atraves de varias APIs para cubrir movilidad, entorno y navegación:

- **Movilidad (EMT):** Disponibilidad de BiciMAD, Llegadas de autobuses y ocupación de parkings.

- **Meteorología (Meteoblue):** Consulta el estado del tiempo por zona geográfica para alimentar el motor de decisiones.
- **Navegación (OpenRouteService):** Permite calcular la ruta exacta entre dos puntos geográficos (origen y destino), devolviendo la geometría del trayecto y los tiempos estimados.

Plataforma de Integración (n8n) El sistema n8n gestiona ahora flujos adicionales para orquestar estas nuevas capacidades:


- **Flujo Meteorológico:** Consulta las condiciones climáticas actuales.
- **Flujo de Enrutamiento:** Recibe las coordenadas de dos puntos seleccionados por el usuario, consulta OpenRouteService y devuelve la polilínea para ser pintada en el mapa.

Sistema de Recomendación y Navegación El gemelo digital asiste en la decisión de manera integral:

- **Recomendación Climática:** Si **Meteoblue** indica condiciones favorables (buen clima), sugiere BiciMAD; si hay lluvia/mal tiempo, recomienda Autobuses.
- **Planificación de Viaje:** Gracias a **OpenRouteService**, el usuario no solo ve dónde están las estaciones, sino que puede visualizar el trazado real de la ruta para ir de un punto A a un punto B, facilitando la orientación espacial.

3.3 Flujos de Datos entre Componentes

Flujo de Datos del Sistema



El flujo sigue una arquitectura cliente-servidor con integración mediante middleware:

1. **Solicitud de Usuario:** El usuario interactúa con el mapa (selecciona origen/destino o consulta una zona).
2. **Orquestación n8n:**
 - a. Si pide ruta: n8n llama a **OpenRouteService** y devuelve las coordenadas del trazado (GeoJSON).
 - b. Si consulta disponibilidad: n8n llama a **Meteoblue** y a las APIs de EMT.
3. **Lógica de Negocio:** El sistema cruza los datos. Por ejemplo, al calcular una ruta, puede advertir si el clima en el destino es desfavorable.
4. **Monitorización (Background):** Paralelamente, el cliente envía cada 30 segundos un lote de métricas a PostgreSQL + TimescaleDB/Grafana para evaluar el rendimiento de estas interacciones.

4. Implementación detallada

4.1 Descripción técnica de cada módulo del prototipo

Módulo 1: Generación y Procesamiento de Datos Se consumen las APIs de EMT, Meteoblue y OpenRouteService. Los workflows de n8n normalizan las respuestas. En el caso del enrutamiento, se procesa la respuesta de OpenRouteService para extraer la geometría (LineString) y las instrucciones de navegación, entregándolas al frontend en un formato ligero.

Módulo 2: Funcionamiento del Gemelo Digital El frontend integra estas funcionalidades en el mapa Leaflet:

- **Visualización de Rutas:** Al seleccionar dos puntos, se dibuja una polilínea dinámica sobre el mapa indicando el camino a seguir.
- **Contexto Climático:** Se muestra una recomendación visual (Bici vs Bus) basada en los datos de Meteoblue.
- **Sincronización:** La ruta se actualiza si el usuario cambia los puntos de interés, manteniendo la fluidez de la SPA.

Módulo 3: Arquitectura de Monitorización Se mantiene el pipeline de observabilidad: Captura (Cliente) → Ingesta (n8n) → Persistencia (TimescaleDB) → Visualización (Grafana). Esto permite medir, por ejemplo, cuánto tarda en cargarse una ruta de OpenRouteService frente a la carga de paradas de la EMT.

4.2 Código Relevante y Evidencias

Se ha integrado código JavaScript en el cliente para manejar la selección de puntos de ruta y la petición al nuevo endpoint de n8n conectado a OpenRouteService. En n8n, se

añadieron los nodos HTTP Request específicos para Meteoblue y OpenRoute, además del flujo de inserción SQL paralela para las métricas.

5. Resultados y Validación

Para la evaluación del sistema se utiliza Grafana, permitiendo medir el rendimiento técnico y la experiencia de usuario con los siguientes resultados reales, se pueden acceder a ellos dependiendo del momento y la duración que quiera, es decir puede por ejemplo escoger analizar los valores en 1h o en todo el día:

5.1 KPIs y Métricas Obtenidas

5.1.1. Interacción del Usuario (Tab Switches)



- **Total de cambios de pestaña: 440.** Indica un uso activo explorando diferentes modos de transporte. Esta métrica nos ayudará en un futuro a analizar cuantas personas interactúan con la web
- **Duración promedio por pestaña: 7.90 segundos.** Navegación rápida.
- **Duración máxima: 30.8 segundos.**

5.1.2. Rendimiento del Sistema (API Calls)

- **Total de llamadas HTTP: 139 requests.**
- **Tiempo promedio de respuesta: 959 milisegundos.**
 - o *Evaluación:* El tiempo es elevado (~1s) sin embargo es normal ya que es un mínimo producto viable y no está optimizado. Además la inclusión de APIs externas adicionales (Meteoblue, OpenRouteService) sin una estrategia de caché agresiva contribuye a esta latencia.
- **Cache Hit Rate: 0%.** Confirmación de que todas las consultas (incluyendo rutas repetidas) van a las APIs externas.

5.1.3. Observabilidad Visual

El dashboard de Grafana muestra la evolución de latencias y errores, permitiendo distinguir si un retraso proviene de la EMT, del cálculo de la ruta (OpenRoute) o de la consulta climática.



5.2 Validación Funcional

- **Rutas:** Se validó exitosamente el trazado de rutas entre puntos distantes de Madrid, visualizándose correctamente la polilínea sobre las calles en el mapa.
- **Recomendación:** El sistema cruzó correctamente los datos: ante lluvia simulada, recomendó bus; ante sol, recomendó bici.

5.3 Limitaciones y lecciones aprendidas

- Limitaciones: No se implementó inteligencia artificial para predicciones; la actualización automática depende de la interacción del usuario; algunas APIs externas tienen retrasos o datos incompletos.
- Lecciones aprendidas: La separación de capas (API → n8n → frontend) facilita la escalabilidad y el mantenimiento; el uso de lazy loading y caché local mejora significativamente la eficiencia; la sincronización automática de listas y mapas es clave para la coherencia de la información.

6. Conclusiones y futuras mejoras

6.1 Valor generado por el prototipo

El gemelo digital se consolida como un asistente integral de movilidad:

- **Planificación Completa:** Ya no solo informa sobre la disponibilidad (EMT), sino que resuelve el "cómo llegar" mediante OpenRouteService, cerrando el ciclo de la necesidad del usuario.
- **Inteligencia Contextual:** La integración de Meteoblue permite decisiones más inteligentes y confortables para el ciudadano.
- **Control Operacional:** Grafana ofrece una visión transparente del rendimiento, crucial al depender ahora de múltiples proveedores externos (EMT, Meteoblue, OpenRoute).

6.2 Posibles avances futuros


- **Optimización de Caché:** Crítico para reducir los 959ms de latencia. Rutas comunes y datos climáticos (que no cambian cada segundo) deben cachearse.
- **Rutas Multimodales:** Utilizar OpenRouteService para combinar modos: "Ir andando a la parada de bus X, coger la línea de bus x, bajarse en la parada y, y andar hasta el destino".


6.3 Transferibilidad a otros ámbitos/sectores

La arquitectura modular (n8n + APIs externas + Monitorización) es altamente replicable para cualquier sistema que requiera logística y geolocalización, permitiendo cambiar las fuentes

de datos (ej. usar Google Maps en lugar de OpenRoute) sin alterar la estructura base del sistema.

7. Imagenes Interfaz





8. Enlace repositorio

https://github.com/Berniquindimil/madrid_digital_twin.git

9. Referencias

1. <https://www.comunidad.madrid/noticias/2025/02/19/comunidad-madrid-logra-record-historico-1700-millones-viajeros-su-transporte-publico#:~:text=La%20Comunidad%20de%20Madrid%20ha,anterior%20m%C3%A1ximo%20logrado%20en%202007.>
2. <https://its.berkeley.edu/news/simulating-future-role-digital-twins-transportation-planning-ga-dr-anu-kuncheria>
3. <https://www.digitalbluefoam.com/post/exploring-digital-twin-in-traffic-management-for-smart-transportation-systems>
4. <https://www.hupi.eus/project/analisis-de-la-demanda-y-prediccion-de-la-ocupacion-en-el-transporte-publico/>
5. https://es.wikipedia.org/wiki/Simulation_of_Urban_MObility
6. <https://www.theagilityeffect.com/es/article/como-el-machine-learning-puede-aumentar-la-fluidez-en-una-zona-urbana-de-traffic-denso/>

